Департамент образования и науки города Москвы Государственное автономное образовательное учреждение высшего образования города Москвы «Московский городской педагогический университет» Институт цифрового образования Департамент информатики управления и технологий

Ли Александр Андреевич БД-241м

Практическая работа 1. Введение в большие данные и их хранение. Инструменты обработки больших данных (Hadoop)

Направление подготовки/специальность

38.04.05 - Бизнес-информатика

Бизнес-аналитика и большие данные

(очная форма обучения)

Вариант 12

Москва

Цель

Изучить основные операции и функциональные возможности системы, что позволит понять принципы работы с данными и распределенными вычислениями.

Основная часть

Запускаем hadoop

Start-dfs.sh

```
hadoop@devopsvm:~ Q = - - ×

devops@devopsvm:~$ sudo su - hadoop
[sudo] password for devops:
hadoop@devopsvm:~$ start-dfs.sh

Starting namenodes on [localhost]

Starting datanodes

Starting secondary namenodes [devopsvm]

2025-02-20 23:09:52,875 WARN util.NativeCodeLoader: Unable to load native-hadoop
library for your platform... using builtin-java classes where applicable
hadoop@devopsvm:~$ S
```

Рис.1 Запускаем файловую систему

Start-yarn.sh

```
hadoop@devopsvm:~$ start-yarn.sh
Starting resourcemanager
Starting nodemanagers
hadoop@devopsvm:~$
```

Рис. 2 Запускаем yarn

Проверяем запущенные службы командой

jps

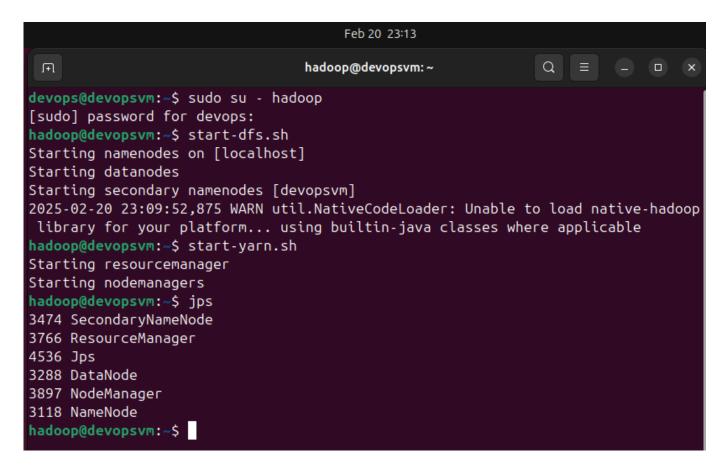


Рис. 3 Проверка запущенных служб

Проверяем доступность запущенных систем

Переходим по ссылке для проверки запущен ли dfs по ссылке

Localhost:9870/dfshealth.html#tab-overview

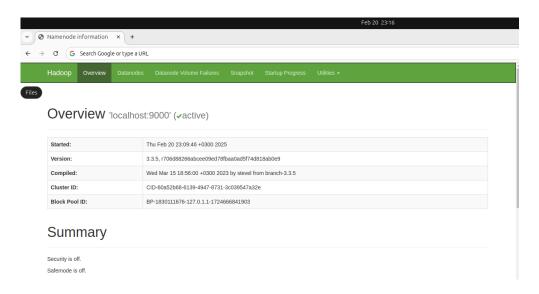


Рис.4 проверка доступности систем

Проверяем запущен ли yarn по ссылке

Localhost:8088/cluster

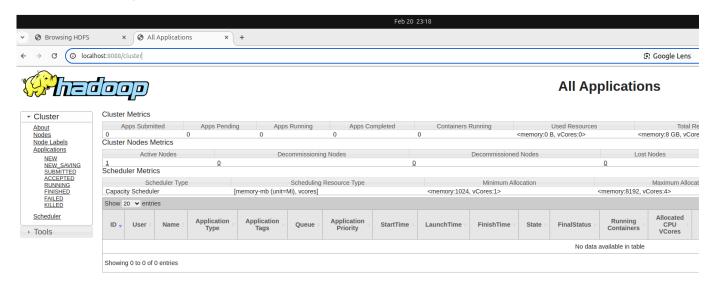


Рис.5 Проверка работы yarn

Создаем пользователя и каталог командой

Hdfs dfs -mkdir -p /lee/Hadoop/input

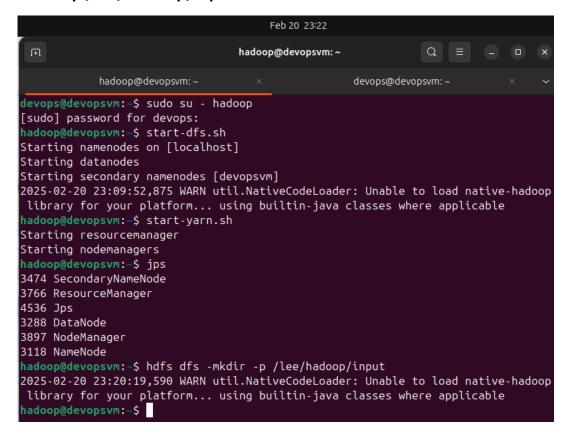


Рис.6 Создание пользователя

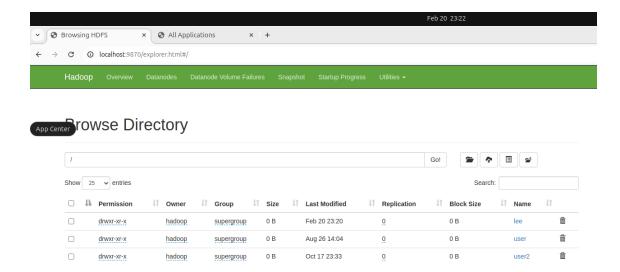


Рис.7 Проверка созданного пользователя

Скачиваем данные

wget

https://raw.githubusercontent.com/BosenkoTM/Distributed_systems/main/practice/2 024/I w_01/GDP.csv

```
hadoop@devopsvm:~$ wget https://raw.githubusercontent.com/BosenkoTM/Distributed_
systems/main/practice/2024/lw_01/GDP.csv
--2025-02-20 23:25:10-- https://raw.githubusercontent.com/BosenkoTM/Distributed
_systems/main/practice/2024/lw_01/GDP.csv
Resolving raw.githubusercontent.com (raw.githubusercontent.com)... 185.199.109.1
33, 185.199.108.133, 185.199.111.133, ...
Connecting to raw.githubusercontent.com (raw.githubusercontent.com)|185.199.109.
133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 30268 (30K) [text/plain]
Saving to: 'GDP.csv.1'
GDP.csv.1
                   in 0.06s
2025-02-20 23:25:11 (523 KB/s) - 'GDP.csv.1' saved [30268/30268]
hadoop@devopsvm:~$
```

Рис.8 Скачиваем данные

Создаем каталог для данных

Hdfs dfs -mkdir -p /lee/Hadoop/input/economic_data

```
nadoop@devopsvm:~$ hdfs dfs -mkdir -p /lee/hadoop/input/economic_data
2025-02-20 23:29:19,690 WARN util.NativeCodeLoader: Unable to load native-hadoop
library for your platform... using builtin-java classes where applicable
nadoop@devopsvm:~$
```

Рис.9 Создание каталога economic data

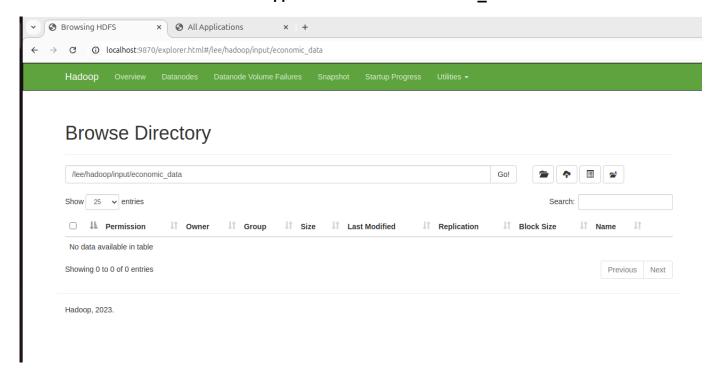


Рис.10 Проверка созданного каталога economic data

Переносим данные в каталог

Hdfs dfs -put GDP.csv /lee/Hadoop/input/economic_data

```
2025-02-20 23:31:22,106 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable hadoop@devopsvm:~$
```

Рис.11 Перенос данных в каталог

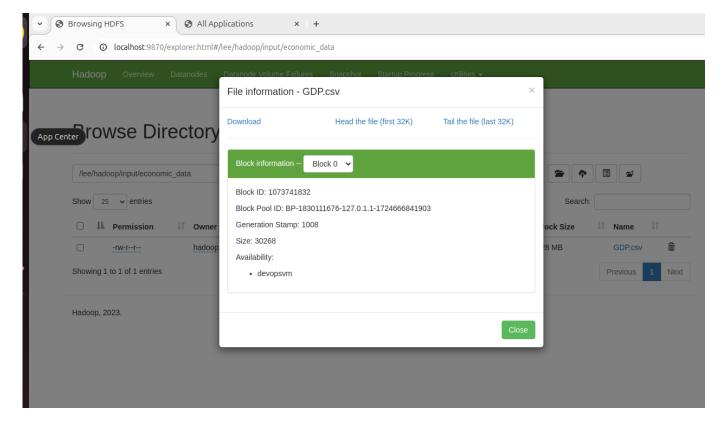


Рис.12 Проверка перенесенных данных

Задаем права доступа

hdfs dfs -chmod 777 /lee/hadoop/input/economic_data

```
hadoop@devopsvm:~$ hdfs dfs -chmod 777 /lee/hadoop/input/economic_data
2025-02-20 23:34:35,919 WARN util.NativeCodeLoader: Unable to load native-hadoop
library for your platform... using builtin-java classes where applicable
hadoop@devopsvm:~$
```

Рис.13 Устанавливаем права доступа

Обрабатываем данные при помощи Spark

Spark-shell

Рис.14 Запуск spark

Загружаем данных из hdfs

val data = spark.read.option("header", "true").csv("file:///home/hadoop/GDP.csv")

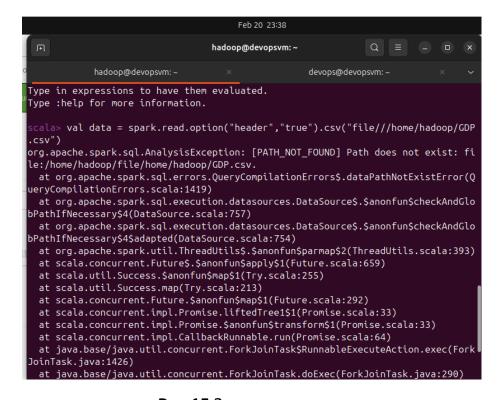


Рис.15 Загрузка данных

Проверка полученной схемы данных

data.printSchema()

```
cala> data.printSchema()
root
 |-- Country: string (nullable = true)
 |-- Year: string (nullable = true)
 |-- GDP: string (nullable = true)
 |-- Urban_population: string (nullable = true)
 |-- Industry: string (nullable = true)
 |-- Business: string (nullable = true)
 |-- Mining: string (nullable = true)
 |-- Manufacturing: string (nullable = true)
 |-- Electricity_supply: string (nullable = true)
 |-- Water_supply: string (nullable = true)
 |-- Construction: string (nullable = true)
Retail trade: string (nullable = true)
Transportation: string (nullable = true)
 |-- Accommodation: string (nullable = true)
  -- Information: string (nullable = true)
 |-- Financial: string (nullable = true)
 -- Real estate : string (nullable = true)
-- Professional_scientific: string (nullable = true)
     Administrative: string (nullable = true)
  -- Education: string (nullable = true)
```

Рис.12 Выводим схему

Вычисление среднего значения GDP

val result = data.selectExpr("avg(GDP) as avg_GDP")

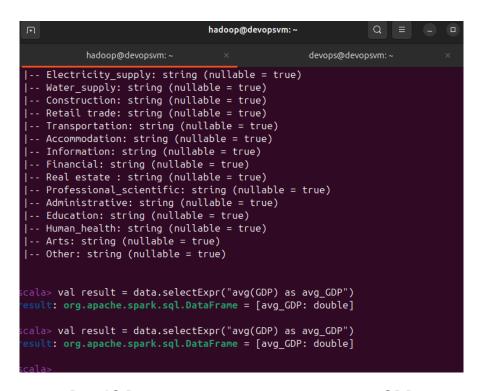


Рис.13 Вычисление среднего значения GDP

Сохраняем результата в CSV файл

result.write.option("header", "true").csv("/home/hadoop/output/avg GDP.csv")

```
hadoop@devopsvm: ~
           hadoop@devopsvm: ~
                                                  devops@devopsvm: ~
|-- Retail trade: string (nullable = true)
|-- Transportation: string (nullable = true)
|-- Accommodation: string (nullable = true)
|-- Information: string (nullable = true)
|-- Financial: string (nullable = true)
|-- Real estate : string (nullable = true)
|-- Professional_scientific: string (nullable = true)
|-- Administrative: string (nullable = true)
|-- Education: string (nullable = true)
|-- Human_health: string (nullable = true)
|-- Arts: string (nullable = true)
|-- Other: string (nullable = true)
scala> val result = data.selectExpr("avg(GDP) as avg GDP")
esult: org.apache.spark.sql.DataFrame = [avg_GDP: double]
scala> val result = data.selectExpr("avg(GDP) as avg_GDP")
esult: org.apache.spark.sql.DataFrame = [avg_GDP: double]
cala> result.write.option("header","true").csv("/home/hadoop/output/avg_GDP.csv
```

Рис.14 сохранение результатов

Переходим в директорию с результатами

cd /home/hadoop/output/avg GDP.csv

```
hadoop@devopsvm:~$ cd output/
hadoop@devopsvm:~/output$ ls
avg_GDP.csv avg_GDR.csv
hadoop@devopsvm:~/output$
```

Рис.15 Проверяем полученный файл

Загружаем полученный файл в HDFS

hdfs dfs -put /home/hadoop/output/avg_GDP.csv /user01/hadoop/input/

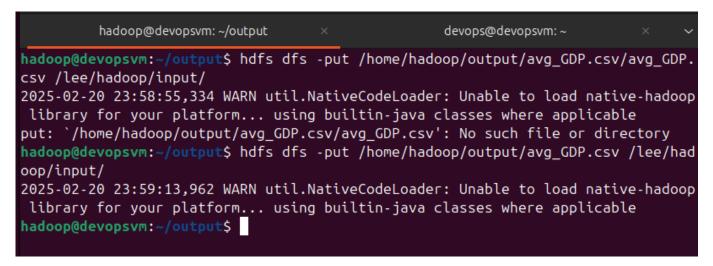


Рис.16 Загрузка файла в HDFS

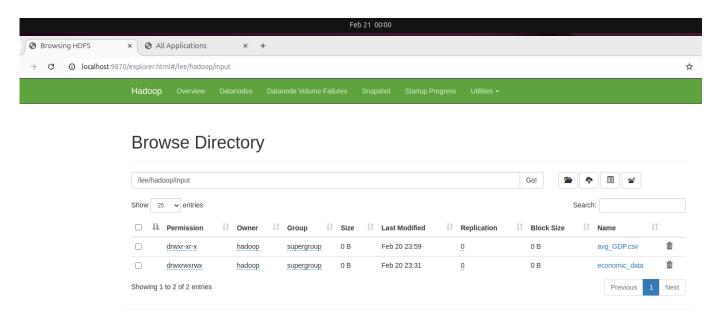


Рис.17 Проверка загруженного файла в hdfs

Проверка загрузки

hdfs dfs -ls /user01/hadoop/input/

```
hadoop@devopsvm: ~/output
         hadoop@devopsvm: ~/output
                                                   devops@devopsvm: ~
nadoop@devopsvm:~/output$ hdfs dfs -put /home/hadoop/output/avg_GDP.csv/avg_GDP.
csv /lee/hadoop/input/
2025-02-20 23:58:55,334 WARN util.NativeCodeLoader: Unable to load native-hadoop
library for your platform... using builtin-java classes where applicable
put: `/home/hadoop/output/avg_GDP.csv/avg_GDP.csv': No such file or directory
hadoop@devopsvm:~/output$ hdfs dfs -put /home/hadoop/output/avg_GDP.csv /lee/had
oop/input/
2025-02-20 23:59:13,962 WARN util.NativeCodeLoader: Unable to load native-hadoop
library for your platform... using builtin-java classes where applicable
nadoop@devopsvm:~/output$ hdfs dfs -ls /lee/hadoop/input/
2025-02-21 00:01:13,344 WARN util.NativeCodeLoader: Unable to load native-hadoop
library for your platform... using builtin-java classes where applicable
Found 2 items
drwxr-xr-x
             - hadoop supergroup
                                          0 2025-02-20 23:59 /lee/hadoop/input/a
vg_GDP.csv
                                          0 2025-02-20 23:31 /lee/hadoop/input/e
drwxrwxrwx
            - hadoop supergroup
conomic_data
nadoop@devopsvm:~/output$
```

Рис.18 Проверка загрузки

Завершение работы с Hadoop

stop-yarn.sh

stop-dfs.sh

stop-all.sh

Проверка остановки всех процессов: jps

```
hadoop@devopsvm:~/output$ stop-yarn.sh
Stopping nodemanagers
^[[AStopping resourcemanager
hadoop@devopsvm:~/output$ stop-dfs.sh
Stopping namenodes on [localhost]
Stopping datanodes
Stopping secondary namenodes [devopsvm]
2025-02-21 00:02:56,752 WARN util.NativeCodeLoader: Unable to load native-hadoop
library for your platform... using builtin-java classes where applicable
hadoop@devopsvm:~/output$ jps
23902 Jps
hadoop@devopsvm:~/output$
```

Рис.18 завершение

Задание для самостоятельной работы

Подключиться к HDFS и убедиться, что файл доступен по пути hdfs://localhost:9000/lee/hadoop/economic_data/GDP.csv

Запускаем jupyterlab и загружаем файлы из hdfs

File_path= "hdfs://localhost:9000/lee/Hadoop/input/economic_data/GDP.csv"

df = spark.read.csv(file_path, header=True, inferShema =True)

df.show(5)

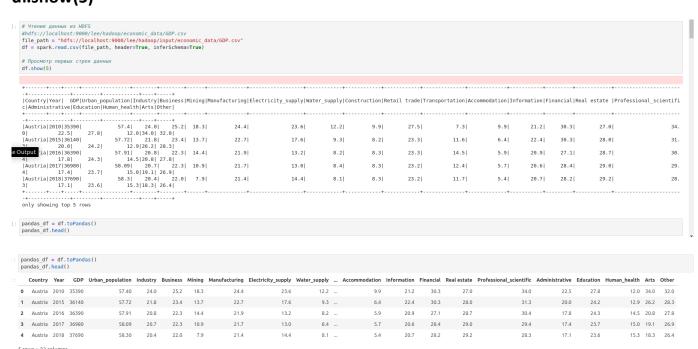


Рис.19 Загружаем данные из hdfs и выводим 5 строк полученных данных

Проверяем структуру данных и типы столбцов.

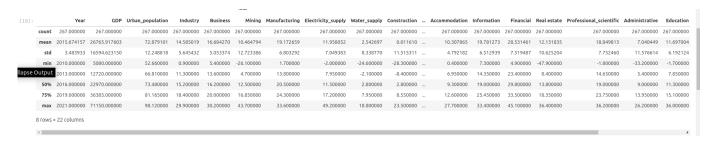


Рис. 20 Проверка структуры данных

Просматриваем типы данных столбцов

Print(pandas_df.dtypes)

Country	object
Year	int32
GDP	int32
Urban_population	float64
Industry	float64
Business	float64
Mining	float64
Manufacturing	float64
Electricity_supply	float64
Water_supply	float64
Construction	float64
Retail trade	float64
Transportation	float64
Accommodation	float64
Information	float64
Financial	float64
Real estate	float64
Professional_scientific	float64

Рис.21 Тип данных столбцов

Проверяем данные на наличие пропущенных.

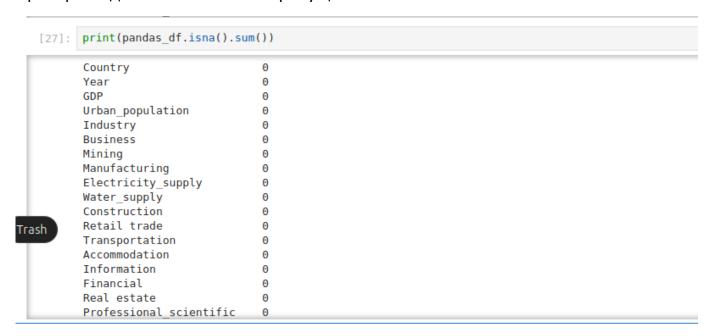


Рис. 22 Проверка полученных значений

Вычисляем среднее, медиану, минимум и максимум для экономических параметров.

```
Print("mean:",pandas_df['GDP'].mean())
```

Print("median:",pandas_df['GDP'].median())

Print("min:",pandas_df['GDP'].min())

Print("max:",pandas_df['GDP'].max())

```
[28]: print("mean:",pandas_df['GDP'].mean())
    print("median:",pandas_df['GDP'].median())
    print("min:",pandas_df['GDP'].min())
    print("max:",pandas_df['GDP'].max())

mean: 26765.917602996255
    median: 22970.0
    min: 5080
    max: 71150
```

Рис.23 Вычисляем параметры

Выявляем тенденцию

```
Trend = pandas_df.groupby('Year')['GDP'].mean()
```

Print (trend)

```
[29]: trend = pandas df.groupby('Year')['GDP'].mean()
      print (trend)
      2010
             25706.521739
            26402.000000
      2011
      2012
             26309.500000
      2013
              25521.428571
      2014
             23851.904762
      2015
             27545.238095
      2016
              26578.260870
      2017
             27256.086957
      2018
              27821.304348
      2019
              28246.250000
      2020
              27031.666667
      2021
              28374.166667
      Name: GDP, dtype: float64
```

Рис.24 Выявление тенденций

Строим временные ряды, чтобы понять, как изменялась их экономика с течением времени для Италии

Italy_data = pandas_df[pandas_df['Country'] == 'Italy']

```
Italy_summary_statistics = Italy_data.describe()
plt.figure(figsize=(10,6))
plt.plot(Italy_data['Year'],Italy_data['GDP'],marker = 'o', linestyle ='-', color = 'b', label = 'GDP')
plt.title('GDP of Italy over years')
plt.xlabel('year')
plt.ylabel('GDP')
plt.legend()
plt.show()
```

Italy_summary_statistics

```
: # Фильтрация данных только для Italy
Italy_data = pandas_df[pandas_df['Country'] == 'Italy']

# Отображение статистики для Italy
Italy_summary_statistics = Italy_data.describe()

# Визуализация ВВП (GDP) для Italy по годам
plt.figure(figsize=(10, 6))
plt.plot(Italy_data['Year'], Italy_data['GDP'], marker='o', linestyle='-', color='b', label='GDP')
plt.xlabel('GDP of Italy Over Years')
plt.xlabel('Year')
plt.ylabel('GDP')
plt.legend()
plt.show()
Italy_summary_statistics
```

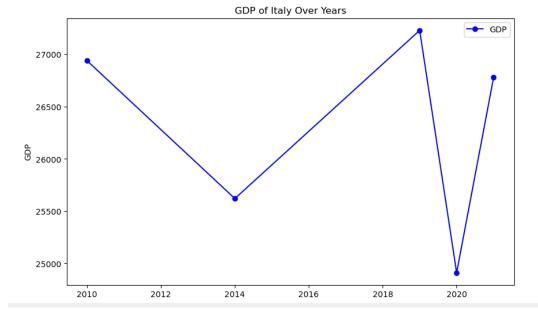


Рис.25 Построение временного ряда

Строим диаграммы для сравнения экономических показателей.

italy_data = pandas_df[pandas_df['Country'] == 'Italy']
labels = ['Industry', 'Business', 'Mining', 'Manufacturing', 'Electricity_supply',
'Water_supply','Retail trade', 'Transportation', 'Accommodation',
'Information','Financial', 'Professional_scientific', 'Administrative',
'Education','Human_health', 'Arts', 'Other']

data_mean_italy = italy_data[labels].mean().values
plt.figure(figsize=(10, 6))

plt.bar(labels,data_mean_italy,color = 'blue')

plt.xticks(rotation=90) plt.legend() plt.tight_layout() plt.show()

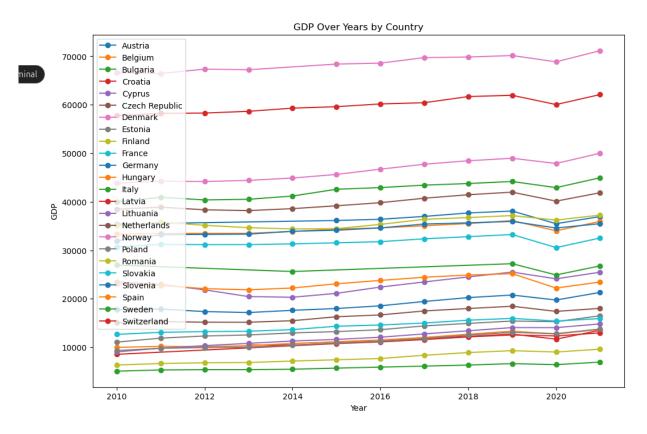


Рис. 26 Диаграмма для сравнения экономических показателей

Фильтруем данные для Италии

italy_data = pandas_df[pandas_df['Country'] == 'Italy']

labels = ['Industry', 'Business', 'Mining', 'Manufacturing', 'Electricity_supply',
'Water_supply',

'Construction', 'Retail trade', 'Transportation', 'Accommodation', 'Information',

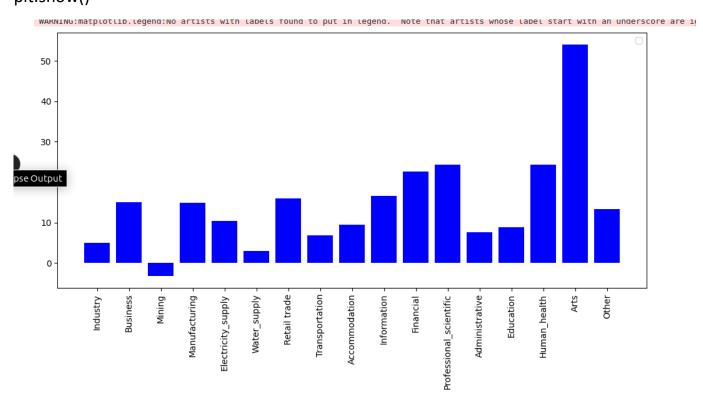


Рис. 26 Диаграмма для сравнения экономических показателей для Италии

Сохраняем результат анализа и визуализации в формате CSV.

italy_data_spark = spark.createDataFrame(Italy_data)

file_path_hdfs =

"hdfs://localhost:9000/lee/hadoop/input/economic_data/ltaly_data.csv"

italy_data_spark.write.csv(file_path_hdfs, header=True, mode='overwrite')

Сохраняем обработанные данные обратно в HDFS

Browse Directory

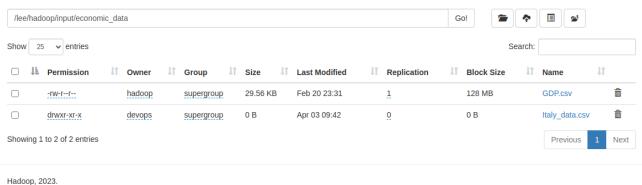


Рис.27 Сохраняем обработанные данные в hdfs

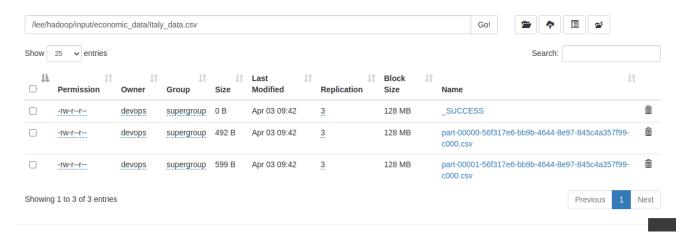


Рис.28 Сохраняем обработанные данные в hdfs



Рис.29 Сохраняем обработанные данные в hdfs

Индивидуальное задание

Вариант 12

Исторические данные по акциям Сургутнефтегаз

https://ru.investing.com/equities/surgutneftegas_rts-historical-data

Так как ссылка не работала, нашёл в интернете данные по акциям Сургутнефтегаз в период с 03.09.2020 по 03.04.2025

Для начала создаем каталог в hdfs

Showing 1 to 1 of 1 entries

Hadoop, 2023.

Hdfs dfs -mkdir -p /lee/hadoop/input/surgutneftgaz



Рис.30 Создание каталога surgutneftgaz в hdfs

Переносим файл из пользователя devops в пользователя Hadoop sudo mv /home/devops/Desktop/dataset_surgutneftgaz.csv /home/hadoop Переносим данные в каталог

Hdfs dfs -put dataset_surgutneftgaz.csv /lee/Hadoop/input/economic_data

Previous

Рис.31 Переносим данные об акциях в hdfs

Устанавливаем права доступа

hdfs dfs -chmod 777 /lee/hadoop/input/surgutneftgaz

```
hadoop@devopsvm:~$ hdfs dfs -chmod 777 /lee/hadoop/input/surgutneftgaz
2025-04-03 10:17:58,590 WARN util.NativeCodeLoader: Unable to load native-hadoop
library for your platform... using builtin-java classes where applicable
hadoop@devopsvm:~$
```

Рис.32 Устанавливаем права доступа

Загружаем данные из hdfs
Import pandas as pd
Import matplotlib.pyplot as plt
From pyspart.sql import SparkSession
Spark = SparkSession.builder\
.appName("Economic Data Analysis")\
.config("spark.hadoop.fs.defaultFS","hdfs://localhost:9000")\
.get0Create()
Spark.conf.set("spark.sql.shuffle.partition", "50")
File_path = "hdfs://localhost:9000/lee/Hadoop/input/surgutneftgaz/dataset.csv"
Df= spark.read.csv(file_path, header = True, inferSchema = True)
Df.show(5)

```
[1]: !pip install pyspark
       Requirement already satisfied: pyspark in /home/devops/.config/jupyterlab-desktop/jlab_server/lib/python3.12/site-packages (3.5.3)
       Requirement already satisfied: py4j==0.10.9.7 in /home/devops/.config/jupyterlab-desktop/jlab_server/lib/python3.12/site-packages (from pyspark) (0.10.9.7)
      import matplotlib.pyplot as plt
[3]: from pyspark.sql import SparkSession
       # Создание SparkSession
       spark = SparkSession.builder '
           .appName("Economic Data Analysis") \
           .config("spark.hadoop.fs.defaultFS", "hdfs://localhost:9000") \
            .config("spark.ui.port", "4050") \
      # Установка количества разделов для shuffle операций spark.conf.set("spark.sql.shuffle.partitions", "50")
      25/04/03 11:04:47 WARN Utils: Your hostname, devopsym resolves to a loopback address: 127.0.1.1; using 192.168.31.165 instead (on interface enp0s3) 25/04/03 11:04:47 WARN Utils: Set SPARK_LOCAL_IP if you need to bind to another address Setting default log level to "WARN".
       To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel)
      25/04/03 l1:04:48 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
      #hdfs://localhost:9000/lee/hadoop/economic_data/GDP.csv
file_path = "hdfs://localhost:9000/lee/hadoop/input/surgutneftgaz/dataset.csv"
      df = spark.read.csv(file_path, header=True, inferSchema=True)
      df.show(5)
              data| price| open| max| min|volume|change|
       |03.04.2025|25,310|25,265|25,495|25,190| 4,96M|-0,06%|
       [02.04.2025]25,325]24,560[25,460]24,450[63,48M] 3,11%
       |01.04.2025|24,560|25,535|25,845|24,410|49,85M|-3,82%|
|31.03.2025|25,535|25,570|25,750|24,350|61,14M| 0,24%|
       [28.03.2025]25,475]26,165]26,285]25,400[56,68M]-2,58%]
       only showing top 5 rows
```

Рис.33 Загрузка данных в hdfs

Просматриваем полученные данные

```
pandas df = df.toPandas()
[5]:
     pandas df.head()
[5]:
             data
                    price
                           open
                                   max
                                           min volume change
     0 03.04.2025 25,310 25,265 25,495 25,190
                                                 4,96M
                                                        -0,06%
     1 02.04.2025 25,325 24,560 25,460 24,450
                                                63,48M
                                                         3,11%
     2 01.04.2025 24,560 25,535 25,845
                                        24,410
                                                49,85M
                                                        -3,82%
     3 31.03.2025 25,535 25,570 25,750 24,350
                                               61,14M
                                                         0,24%
     4 28.03.2025 25,475 26,165 26,285 25,400 56,68M
                                                        -2,58%
```

Рис.34 Просмотр полученные данные

Фильтрация данных за 2020 год, преобразуем date из числового формата в дату pandas_df["data"] = pd.to_datetime(pandas_df["data"], dayfirst=True) df_2020 = pandas_df[pandas_df["data"].dt.year == 2020] print(df_2020.head())

```
[13]: pandas_df["data"] = pd.to_datetime(pandas_df["data"],dayfirst = True)
[14]: pandas_df.head()
[14]:
                                          min volume change
              data price open
                                  max
      0 2025-04-03 25,310 25,265 25,495 25,190 4,96M
                                                      -0,06%
      1 2025-04-02 25,325 24,560 25,460 24,450 63,48M
                                                      3,11%
      2 2025-04-01 24,560 25,535 25,845 24,410 49,85M
                                                      -3.82%
      3 2025-03-31 25,535 25,570 25,750 24,350 61,14M
                                                       0,24%
      4 2025-03-28 25.475 26.165 26.285 25.400 56.68M
                                                      -2.58%
[17]: df 2020 = pandas df[pandas df["data"].dt.year== 2020]
      print(df 2020.head(10))
                                 open
      1057 2020-12-30 35,985 35,820 36,330 35,600 32,51M
                                                                0,83%
      1058 2020-12-29 35,690 35,450 36,040 35,210 32,31M
                                                                 1,22%
      1059 2020-12-28 35,260
                               35,050 35,535
                                                35,050 20,17M
      1060 2020-12-25 35,060 35,000 35,100 34,910
                                                        6,53M
                                                                 0.30%
      1061 2020-12-24 34,955 34,910 35,075 34,785 12,05M -0,04%
      1062 2020-12-23 34,970 34,895 35,055
                                                34,705
                                                        20,27M
                                                                 0,37%
      1063 2020-12-22 34,840 34,350 35,055
                                                34,115 28,29M
                                                                 1,10%
      1064 2020-12-21 34,460 34,990 35,070 34,040 42,18M -1,80%
      1065 2020-12-18 35,090 35,035 35,310 34,685 35,60M 0,09% 1066 2020-12-17 35,060 35,480 35,605 34,890 47,98M -0,40%
```

Рис.35 Преобразование date в формат даты

Рассчитываем стандартное отклонение цены открытия

```
Df_2020["open"] = df_2020["open"].str.replace(",","").astype(float)
```

Std_open =df_2020["open"].std()

Print(f"standart deviation:{std_open:.2f}")

```
df_2020["open"] = df_2020["open"].str.replace(",", "").astype(float)

std_open = df_2020["open"].std()
print(f"Standard deviation: {std_open:.2f}")

Standard deviation: 1093.07
```

Рис. 36 Стандартное отклонение цены открытия

Тренд-анализ

```
df_2020["Trend"] = intercept + slope * df_2020["Days"]
plt.figure(figsize=(10, 5))
plt.plot(df_2020["data"], df_2020["open"], label="Цена открытия",
linestyle="dotted", color="blue")
plt.plot(df_2020["data"], df_2020["Trend"], label="Тренд (Линейная
регрессия)", color="red")
plt.xlabel("data")
plt.ylabel("price open")
plt.title("Тренд цены открытия за 2020 год")
plt.legend()
plt.show()
```



Рис.37 Тренд анализ

Расчет волатильности и анализ динамики цен открытия

```
Pandas_df["open"] = pandas_df["open"].str.replace(",",".").astype(float)
```

Volatility =padndas_df["open"].std()

Print(volatility)

```
pandas_df["open"] =pandas_df["open"].str.replace(",",".").astype(float)
volatility = pandas_df["open"].std()
print(volatility)

5.4689643590088295
```

Рис.38 Расчет волатильности

Анализ динамики цен открытия

```
pandas_df["price change"]= pandas_df["open"].pct_change() *100
plt.figure(figsize=(12, 8))
plt.plot(pandas_df["data"],pandas_df["price change"],label= "price change
open",color = "green")
plt.xlabel('data')
plt.ylabel('price change %')
plt.legend()
plt.show()
```

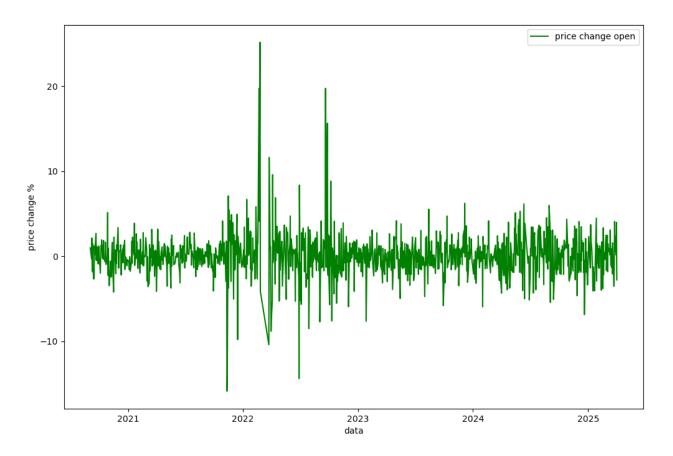


Рис.39 Анализ динамики цен открытия

Заключение

В ходе проделанной лабораторной работы, были изучены основные операции и функциональные возможности системы, что позволило понять принципы работы с данными и распределенными вычислениями, также было выполнено задание по вариантам.